

T.C. ANKARA ÜNİVERSİTESİ MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



BLM 4062 ARAŞTIRMA PROJESİ II BİTİRME PROJESİ
TÜRK DİLLERİ ARASI NÖRAL MAKİNE ÇEVİRİSİ
ALGORİTMASI GELİŞTİRİLMESİ

Zühtü Hilmi DÜZGÜNER
22290012

Danışman: Dr. Öğr. Üyesi İrem ÜLKÜ

Haziran 2026

ÖZET

Bu çalışmada, Türkiye Türkçesinden Azerbaycan Türkçesine (TR-AZ) ve Türkiye Türkçesinden Türkmenceye (TR-TK) İngilizce aracı dil kullanmadan doğrudan çeviri yapabilen çok dilli bir Nöral Makine Çevirisi (NMT) sistemi geliştirilmiştir. Proje, çok katmanlı bir hibrit veri mühendisliği stratejisini benimsemiştir: Doğrudan paralel derlemeler (TurkicNLP, TED konuşmaları, Tatoeba, Wikimedia), İngilizce köprü dil üzerinden pivot madenciliği ve Gemini API ile LLM destekli sentetik veri büyütmesi (TR-TK için 20.014 satır Alpaca; TR-AZ için 9.017 satır OpenSubtitles) birleştirilerek toplamda 66.951 satırlık yüksek standartlı bir paralel veri havuzu (TR-AZ: 33.771, TR-TK: 33.180) oluşturulmuştur.

Temel model olarak Meta AI'nın NLLB-200-distilled-600M (615M parametre) seçilmiş; bu model Parametre Verimli İnce-Ayar (PEFT) çerçevesinde LoRA yöntemiyle ince-ayara tabi tutulmuştur. Toplam parametrelerin yalnızca %1,39'unu (8,65M parametre) güncelleyen LoRA adaptörü, Tesla T4 GPU (15,6 GB VRAM) üzerinde yaklaşık 2 saat 6 dakikada 4 epoch eğitim tamamlamış; eğitim kümesi 59.933 cümle çiftinden oluşmuştur.

İnce-ayar sonucunda dahili test kümesinde TR-AZ için BLEU=25,19 / chrF=54,04 / METEOR=0,5354; TR-TK için BLEU=39,56 / chrF=65,79 / METEOR=0,6248 başarımına ulaşılmıştır. Bu değerler taban modele göre TR-AZ'de +10,79, TR-TK'da ise +27,00 birimlik BLEU artışını temsil etmektedir. Öte yandan önceki dönemde MarianMT mimarisi ve BPE tokenizasyonu ile 1,00 BLEU düzeyinde kalan aynı problem, bu dönemde NLLB-200 + LoRA mimarisine geçilerek 39,56 BLEU seviyesine taşınmıştır. FLORES-200 uluslararası karşılaştırma ölçütündeki başarımların düşüşü, alan kayması ve sentetik veri kullanımının yarattığı dağılım farkıyla açıklanmakta; bu durum gelecek çalışmalar için kapsamlı bir iyileştirme gündemi sunmaktadır.

Anahtar Kelimeler: Nöral Makine Çevirisi, Türk Dilleri, NLLB-200, LoRA, PEFT, Sentetik Veri, Düşük Kaynaklı Çeviri, Transformer.

İÇİNDEKİLER

ÖZET	ii
İÇİNDEKİLER	iii
1. GİRİŞ	1
1.1. Projenin Amacı ve Kapsamı	1
1.2. Problem Tanımı, Motivasyon ve Geçen Dönemden Elde Edilen Dersler	1
1.3. Rapor Organizasyonu	2
2. KURAMSAL ALTYAPI VE LİTERATÜR	4
2.1. Makine Çevirisi Yöntemleri	4
2.2. Transformer Mimarisi ve NLLB-200 Modeli	4
2.3. Parametre Verimli İnce-Ayar: LoRA	4
2.4. Alt-Kelime Tokenizasyonu	5
2.5. Değerlendirme Metrikleri 2.6. İlgili Çalışmalar	5
3. MATERYAL VE YÖNTEM	7
3.1. Genel Sistem Mimarisi	7
3.2. Veri Seti Hazırlığı, Sentezi ve Ön İşleme Mimarisi	7
3.2.1. Doğrudan Paralel Derlemler (Altın Standart İnsan Çevirileri)	7
3.2.2. Pivot (Köprü) Çeviri Madenciliği	8
3.2.3. LLM Destekli Sentetik Veri Büyütme	8
3.3. Veri Temizleme ve Kalite Kontrol Boru Hattı	9
3.4. Bilimsel Uzunluk Analizi ve Token Limiti Belirleme	10
3.5. Nihai Veri Seti Dağılımı	11
3.6. Veri Ön İşleme ve Tokenizasyon	11
3.7. Model Yapılandırması ve LoRA Konfigürasyonu	12
3.8. Eğitim Stratejisi ve Hiperparametreler	12
4. BULGULAR VE TARTIŞMA	14
4.1. Taban Model (Saf Model) Başarımı	14
4.2. Eğitim Süreci Bulguları	14
4.3. İnce-Ayarlı Model Başarımı	15

4.4. Performans Değerlendirmesi	16
4.5. Nitel Analiz: Örnek Çeviri Karşılaştırmaları	17
4.6. FLORES-200 Karşılaştırma Analizi ve Aşırı Uyum	18
5. SONUÇ VE ÖNERİLER	20
KAYNAKLAR	22
EKLER	23
Ek 1 – Eğitim Kodu (TurkDilleriNMT_Colab_yeni_kod.py)	24
Ek 2 – Veri Seti Kaynak Dağılımı Detayları	25

1. GİRİŞ

1.1. Projenin Amacı ve Kapsamı

Bu projenin temel amacı, Türk dil ailesine mensup Türkçe, Azerbaycanca ve Türkmence arasında İngilizce gibi bir aracı dile gereksinim duymadan doğrudan ve yüksek doğruluklu çeviri gerçekleştirebilen çok dilli bir NMT modeli geliştirmektir. Proje, özellikle sondan eklemeli morfolojik yapıya sahip Türk dillerinin dilbilgisel özelliklerini koruyan ve anlamsal bütünlüğü sağlayan uçtan uca (end-to-end) bir sistem ortaya koymayı hedeflemektedir.

Projenin kapsamı şu temel süreçleri kapsamaktadır:

1. Veri Mühendisliği: Çok katmanlı bir hibrit stratejiyle (doğrudan paralel derlem + pivot madenciliği + LLM destekli sentetik üretim) 66.951 satırlık yüksek standartlı bir paralel veri havuzunun oluşturulması.
2. Ön İşleme: Ham verilerin çok adımlı temizlik boru hattından geçirilmesi, bilimsel cümle uzunluk analizinin yapılması ve NLLB-200 tokenizer ile dil etiketi tabanlı tokenizasyonun gerçekleştirilmesi.
3. Model Geliştirme: NLLB-200-distilled-600M modelinin LoRA / PEFT yöntemiyle ince-ayara tabi tutularak TR-AZ ve TR-TK çeviri yönlerinin tek bir çok dilli model altında birleştirilmesi.
4. Değerlendirme: BLEU, chrF ve METEOR metrikleriyle hem dahili test kümesi hem de FLORES-200 uluslararası karşılaştırma ölçütü üzerinde başarımın bağımsız olarak ölçülmesi.

1.2. Problem Tanımı, Motivasyon ve Geçen Dönemden Elde Edilen Dersler

Ticari çeviri sistemleri kaynakça kısıtlı diller arasında çeviri yaparken İngilizceyi köprü dil olarak kullanmaktadır. Türkçeden Azerbaycancaya yapılan bir çeviri arka planda önce İngilizceye, ardından tekrar Azerbaycancaya aktarılmaktadır. Bu iki aşamalı yöntem, yapısal ve dilbilgisel açıdan birbirine yakın Türk dilleri için ciddi sorunlar doğurmaktadır:

- Morfolojik Kayıp: Analitik bir dil olan İngilizce araya girdiğinde, sondan eklemeli Türkçe ve Azerbaycancadaki çekim ekleri ve morfolojik yapılar bozulabilmektedir.
- Anlam Kayması: Doğrudan karşılığı bulunan sözcükler ve deyimler, İngilizce üzerinden çevrildiğinde bağlamsal anlamını yitirebilmektedir.
- Veri Kıtılığı: Azerbaycanca ve özellikle Türkmence için kamuya açık yüksek kaliteli paralel veri miktarı, büyük ölçekli NMT sistemlerinin eğitimi için yetersiz kalmaktadır.

Projenin önceki döneminde (2025-2026 Güz Dönemi), MarianMT mimarisi ve Byte-Pair Encoding (BPE) tokenizasyonu kullanılarak Türkçe-Azerbaycanca dil çifti için bir NMT sistemi geliştirilmiştir. Ancak bu yaklaşımda karşılaşılan kritik sorun, modelin BPE tokenlarını ("@@@" ekleri) çıktıda temizleyememesinden kaynaklanmış ve nihai BLEU-4 skoru 1,00 düzeyinde kalmıştır. Bu başarısızlık, aşağıdaki temel dersleri ortaya koymuştur:

5. Mimarının Kritikliği: Sıfırdan eğitilen veya küçük ön-eğitilmiş modeller (MarianMT), kısıtlı paralel veri koşullarında düşük kaynaklı Türk dilleri için yetersiz kalabilmektedir.
6. Tokenizasyon Uyumluluğu: Çok dilli modellerde BPE yerine dil-agnostik SentencePiece tokenizer kullanılması, OOV (bilinmeyen kelime) sorunlarını ve son işleme (post-processing) karmaşıklığını ortadan kaldırmaktadır.
7. Çok Dillilik Avantajı: İkidilli (bilingual) bağımsız model eğitimi yerine paylaşımlı çok dilli temsil öğrenmenin, benzer Türk dilleri arasında olumlu aktarım (positive transfer) sağlayabileceği göz ardı edilmiştir.

Bu dersler ışığında proje tamamen yeniden tasarlanmış; NLLB-200-distilled-600M ve LoRA mimarisine geçilerek aynı problem çözülmüş, dahili test kümesinde 39,56 BLEU seviyesine ulaşılarak önceki döneme göre yaklaşık 40 birimlik devasa bir başarımlı sıçraması gerçekleştirilmiştir.

1.3. Rapor Organizasyonu

Bu rapor projenin geliştirilme sürecini ve elde edilen sonuçları sistematik biçimde sunmaktadır. Bölüm 2'de NMT, Transformer, NLLB-200, LoRA ve değerlendirme metriklerine ilişkin kuramsal bilgiler verilmektedir. Bölüm 3, çok katmanlı veri mühendisliği sürecini, temizleme boru hattını, uzunluk analizini ve model eğitim yapılandırmasını kapsamaktadır. Bölüm 4'te taban model karşılaştırması, eğitim süreci, ince-ayar sonuçları, nitel örnek çeviriler ve FLORES-200 analizi sunulmaktadır. Bölüm 5'te elde edilen sonuçlar özetlenmekte ve gelecek öneriler sunulmaktadır.

2. KURAMSAL ALTYAPI VE LİTERATÜR

2.1. Makine Çevirisi Yöntemleri

Makine çevirisi tarihsel olarak üç ana döneme ayrılmaktadır: Kural Tabanlı (RBMT), İstatistiksel (SMT) ve Nöral Makine Çevirisi (NMT). Bu projede, kelime dizilerini bir bütün olarak ele alabilen, bağlamsal ilişkileri öğrenebilen ve büyük ön-eğitilmiş modellerden yararlanabilen NMT yaklaşımı benimsenmiştir (Koehn, 2010).

2.2. Transformer Mimarisi ve NLLB-200 Modeli

Vaswani vd. (2017) tarafından önerilen Transformer mimarisi, öz-dikkat (self-attention) mekanizması sayesinde cümledeki tüm kelimeler arasındaki ilişkileri paralel olarak modellemekte; böylece uzun mesafeli bağımlılıklar etkin biçimde öğrenilebilmektedir. Model iki temel bileşenden oluşmaktadır: kaynak cümleyi bağlamsal gömme vektörlerine dönüştüren Kodlayıcı (Encoder) ve bu vektörlerden hedef dil cümlesini üreten Kodçözücü (Decoder).

Meta AI tarafından geliştirilen NLLB-200 (NLLB Team, 2022), 200'den fazla dili birbirine doğrudan çevirebilen çok dilli bir Transformer modelidir. Bu projede kullanılan NLLB-200-distilled-600M varyantı, bilgi damıtma (knowledge distillation) yöntemiyle daha büyük modellerden öğrenilmiş bilgiyi 615 milyon parametreye sıkıştırmaktadır. Model, her dil için ayrı bir dil etiketi tokenı (tur_Latn, azj_Latn, tuk_Latn gibi) tanımlayan paylaşımlı bir SentencePiece sözcük dağarcığına (256.204 token) sahiptir.

2.3. Parametre Verimli İnce-Ayar: LoRA

Büyük ön-eğitilmiş modellerin tüm parametreleri üzerinde ince-ayar yapmak yüksek hesaplama ve bellek maliyeti gerektirmektedir. Hu vd. (2022) tarafından önerilen Düşük Rütbeli Adaptasyon (LoRA), ağırlık güncellemelerini düşük rütbeli matris çarpımı olarak ifade ederek bu sorunu çözmektedir: $\Delta W = BA$; burada $B \in \mathbb{R}^{d \times r}$ ve $A \in \mathbb{R}^{r \times k}$, $r \ll \min(d, k)$. Bu yapı sayesinde orijinal model ağırlıkları dondurulmakta, yalnızca A ve B matrisleri eğitilmektedir. Projemizde LoRA, toplam parametrelerin

yalnızca %1,39'unu (8,65M) güncelleyerek hem bellek tasarrufu hem de hız kazanımı sağlamıştır.

2.4. Alt-Kelime Tokenizasyonu

Türkçe, Azerbaycanca ve Türkmence gibi eklemeli dillerde sözcük dağılımı teorik olarak sınırsız büyüklüğe ulaşabilmektedir. NLLB-200'ün SentencePiece tokenizer'ı, sık geçen sözcükleri bütün hâlde; nadir geçen sözcükleri ise alt parçalara ayırarak morfolojik çeşitliliği kapsayabilmektedir. Bu yaklaşım, geleneksel BPE yönteminin aksine herhangi bir son işleme (post-processing) gerektirmemekte ve çok dilli paylaşımlı bir sözcük dağılımı kullanarak diller arası bilgi aktarımını desteklemektedir.

2.5. Değerlendirme Metrikleri

Modelin başarımını ölçmek için üç tamamlayıcı otomatik değerlendirme metriği kullanılmıştır:

- **BLEU (Bilingual Evaluation Understudy):** Model çıktısı ile referans çeviri arasındaki n-gram örtüşmesini ölçer (Papineni vd., 2002). 0-100 arasında değer alır; yüksek değer daha iyi çeviriyi gösterir.
- **chrF (Character n-gram F-score):** Karakter düzeyinde n-gram eşleşmelerini hesaplar (Popovic, 2015). Morfolojik açıdan zengin dillerde BLEU'ya kıyasla daha hassas sonuçlar sunar.
- **METEOR:** Morfolojik varyasyonları ve eş anlamlıları göz önünde bulunduran bu metrik (Banerjee ve Lavie, 2005), tek referanslı değerlendirme senaryolarında BLEU'dan daha güvenilir sonuçlar vermektedir.

2.6. İlgili Çalışmalar

Türk dilleri arası makine çevirisi, düşük kaynaklı ve morfolojik açıdan zengin dil çiftlerine odaklanan araştırmaların ilgi alanına girmektedir. Salimov vd. (2023), Türkçe-Azerbaycanca dil çifti için doğrudan NMT yaklaşımının İngilizce pivot sistemlere göre

üstünlük sağladığını göstermiştir. NLLB Team (2022), NLLB-200 modeliyle 200 dil için başarımlarını belirlemiş ve bu çalışma projemizin temel noktasını oluşturmuştur. Hu vd. (2022) LoRA yöntemiyle büyük modellerin düşük maliyetle ince-ayara alınabileceğini kanıtlamış; Xu vd. (2023) ise bu yöntemin çok dilli NMT bağlamında da etkin olduğunu göstermiştir.

3. MATERYAL VE YÖNTEM

3.1. Genel Sistem Mimarisi

Geliştirilen sistem iki ana hattan oluşmaktadır: çok katmanlı veri hazırlama hattı ve NLLB-200 LoRA ince-ayar hattı. Sistem Python programlama dili, PyTorch derin öğrenme kütüphanesi, Hugging Face Transformers ve PEFT kütüphaneleri üzerine inşa edilmiştir. Tüm eğitim ve değerlendirme süreçleri Google Colab ortamında Tesla T4 GPU (15,6 GB VRAM) üzerinde yürütülmüştür. Sistem bileşenleri şunlardır:

- Tokenizer: NLLB-200'e ait çok dilli SentencePiece tokenizer (256.204 token dağarcığı).
- Temel Model: facebook/nllb-200-distilled-600M (615.073.792 parametre).
- LoRA Adaptörü: 8.650.752 eğitilebilir parametre (%1,39 oran).
- Eğitici: Hugging Face Seq2SeqTrainer tabanlı özel CustomTrainer.
- Değerlendirici: sacrebleu (BLEU + chrF) ve nltk (METEOR) kütüphaneleri.

3.2. Veri Seti Hazırlığı, Sentezi ve Ön İşleme Mimarisi

Bu projede "az ama yüksek kaliteli veri" prensibi benimsenmiş; düşük kaynaklı Türk dillerindeki veri kıtlığını (data sparsity) aşmak için üç aşamalı, hibrit bir veri toplama stratejisi uygulanmıştır. Dil çiftlerinin dijital varlık oranlarındaki asimetri göz önüne alınarak her dile özel farklı bir veri toplama yaklaşımı izlenmiş; doğrudan paralel derlemler, İngilizce köprü dil üzerinden pivot madenciliği ve LLM destekli sentetik veri büyütmesi birleştirilerek 66.951 satırlık yüksek standartlı bir paralel veri havuzu oluşturulmuştur.

3.2.1. Doğrudan Paralel Derlemler (Altın Standart İnsan Çevirileri)

Dilbilgisi, terminoloji ve yapısal doğruluğu modelin temeline oturtmak için öncelikle akademik ve profesyonel insan çevirileri kullanılmıştır. Bu çerçevede birden fazla açık kaynak kullanılmıştır:

- **TurkicNLP (UD Treebanks):** Açık kaynaklı Turkic NLP projesinden dilbilgisel olarak incelenmiş ve etiketlenmiş TR-AZ için 7.203, TR-TK için 7.135 satır yüksek kaliteli paralel veri projeye dahil edilmiştir.
- **TED Konuşmaları (TED2020):** Özellikle TR-AZ çiftinde geniş bir külliyata ulaşılarak 11.123 satır profesyonel TED çevirisi kullanılmıştır. Türkmençe tarafında ise bu sayı dijital içerik kısıtlılığından dolayı yalnızca 209 satırda kalmıştır.
- **Tatoeba ve Wikimedia:** Doğrudan eşleşen Tatoeba çiftlerinden TR-AZ için 1.123, TR-TK için 50 satır; Türkmençe Wikimedia projelerinden ise 667 satır alınmıştır.

3.2.2. Pivot (Köprü) Çeviri Madenciliği

Doğrudan TR-AZ ve TR-TK eşleşmelerinin yetersiz kaldığı noktalarda, İngilizce (EN) yüksek kaynaklı bir köprü dil olarak kullanılmıştır. Tatoeba veri tabanında algoritmik eşleştirmeler yapılarak EN-AZ ve EN-TR cümle çiftleri, ortak EN cümlesi üzerinden TR-AZ çiftine; EN-TK ve EN-TR çiftleri ise TR-TK çiftine dönüştürülmüştür. Bu yöntemle TR-AZ için 3.296, TR-TK için 3.096 adet yüksek kaliteli paralel çift organik veri havuzuna eklenmiştir. Pivot madenciliğinde elde edilen çiftler, kalite güvencesi amacıyla hizalama ve uzunluk filtrelerinden geçirilmiştir.

3.2.3. LLM Destekli Sentetik Veri Büyütme

İki dilin ihtiyaçları belirgin biçimde farklı olduğu için sentetik üretim stratejisi dillere özel olarak tasarlanmıştır. Bu strateji, projenin en yenilikçi katkısını oluşturmaktadır:

- **TR-TK Alpaca Sentetik Verisi (20.014 satır):** Türkmençe, dijital ortamda en az kaynağa sahip Türk dillerinden biridir; yeterli organik paralel veri bulmak neredeyse imkânsızdır. Bu açığı kapatmak amacıyla İngilizce komut-cevap formatındaki Alpaca veri setindeki 52.002 JSON nesnesi ayrıştırılarak 74.966 adet saf tek dilli Türkmençe cümle çıkarılmıştır. Bu cümlelerin yaklaşık 20.014 adedi Gemini API ile Türkiye Türkçesine çevrilerek yüksek kaliteli, talimat tabanlı (instruction-tuned) paralel veri hâline dönüştürülmüştür. Bu strateji, TR-TK çiftinin eğitim havuzunun taşıyıcı kolonunu oluşturmaktadır.

- **TR-AZ OpenSubtitles Sentetik Verisi (9.017 satır):** TR-AZ çiftinde TED ve TurkicNLP gibi "resmi ve akademik" kaynaklar çoğunluktadır. Modelin günlük konuşma dili, diyaloglar ve sokak Azerbaycancasındaki yetersizliğini gidermek amacıyla OpenSubtitles altyazı veri setinden seçilen 9.017 adet Azerbaycanca cümle, Gemini API ile Türkçeye çevrilerek alan çeşitliliği sağlanmıştır.

Üretilen tüm sentetik çiftler, otomatik güvenilirlik filtrelerinden geçirilerek kalite güvencesi altına alınmıştır.

Çizelge 3.1. Veri Kaynaklarının Türe Göre Dağılımı

Kaynak	Tür	TR-AZ	TR-TK
TurkicNLP (UD Treebanks)	Doğrudan Paralel	7.203	7.135
TED Konuşmaları (TED2020)	Doğrudan Paralel	11.123	209
Tatoeba	Doğrudan Paralel	1.123	50
Wikimedia	Doğrudan Paralel	—	667
Pivot Madenciligi (EN Köprüsü)	Köprü Çevirisi	3.296	3.096
OpenSubtitles + Gemini API	LLM Sentetik	9.017	—
Alpaca (TK) + Gemini API	LLM Sentetik	—	20.014
Alt Toplam (Havuz)	—	31.762	31.171
FLORES-200 Benchmark	Dış Ölçüt	+2.009	+2.009
Genel Toplam	—	33.771	33.180

3.3. Veri Temizleme ve Kalite Kontrol Boru Hattı

Toplanan ham verilerin eğitim kalitesini düşürmemesi için çok adımlı bir RegEx ve kural tabanlı temizleme filtresi (Data Sanitization Pipeline) uygulanmıştır. TED2020, Wikimedia ve Tatoeba gibi kaynaklardan gelen 13.721 ham satır bu boru hattından geçirilmiş; yalnızca %3,6'lık bir veri kaybıyla 13.233 temiz çift elde edilmiştir.

Çizelge 3.2. Veri Temizleme Boru Hattı ve Elenen Kayıtlar

Filtre Adımı	Açıklama	Elenen Kayıt
Hizalama Kontrolü	Boş satırlar ve yalnızca noktalama içeren kısa satırlar	~140
Çevrilmemiş Satırlar	Kaynak-hedef cümlelerin birebir aynı olduğu satırlar (24 TED, 23 Tatoeba)	~47
Alfabe Filtresi	Hedef dilde Kiril harfi içeren satırlar (Wikimedia:12, Tatoeba:4)	~16
Meta/Etiket Temizliği	Referans ve meta etiketi barındıran satırlar	~30
Uzunluk ve Oran Dengesi	Anormal kaynak-hedef uzunluk oranına sahip asimetrik çiftler	~155
Tekilleştirme	Yinelenen (duplikat) cümle çiftleri	~100
TOPLAM	13.721 ham satır → 13.233 temiz çift	488 (%3,6)

3.4. Bilimsel Uzunluk Analizi ve Token Limiti Belirleme

Eğitimdeki max_length (maksimum token) değerini sezgisel değil, veri odaklı bir mühendislik kararına dayandırmak amacıyla veri kümesi genelinde kapsamlı bir cümle uzunluğu analizi gerçekleştirilmiştir.

Çizelge 3.3. Veri Kümesi Cümle Uzunluğu İstatistikleri (Kelime Sayısı)

İstatistik	Değer
Ortalama Cümle Uzunluğu (TR ve AZ/TK)	~8 kelime
95. Yüzdelik Dilim	19 kelime
99. Yüzdelik Dilim	30–31 kelime
Maksimum Gözlemlenen	98 kelime
Eğitim Token Limiti (max_length)	128 token
Değerlendirme Token Limiti (FLORES)	256 token

Bu istatistiksel dağılım ışığında, T4 GPU'nun 15,6 GB VRAM kapasitesinde bellek taşmalarını (OOM) önlemek ve eğitim verimliliğini en üst düzeye çıkarmak amacıyla eğitim tokenizasyon limiti 128 token olarak sabitlenmiştir. Veri setinin %99'undan fazlası bu limite sığırdığı için kırpma (truncation) kaynaklı bilgi kaybı teorik olarak sıfıra indirilmiştir. Bununla birlikte; daha uzun ve çeşitli cümle yapıları barındıran FLORES-200 uluslararası karşılaştırma ölçütünde modelin kısıtlanmaması için değerlendirme aşamasında bu sınır 256 tokena çıkarılmıştır.

3.5. Nihai Veri Seti Dağılımı

Temizleme ve sentetik üretim aşamaları sonrasında havuzda biriken TR-AZ (31.762) ve TR-TK (31.171) paralel cümle çiftleri, değerlendirme metriklerinin güvenilirliğini sağlamak ve veri sızıntısını (data leakage) önlemek amacıyla aşağıdaki şekilde yeniden dağıtılmıştır (Redistribution):

Çizelge 3.4. Nihai Veri Seti Dağılımı

Küme	TR-AZ	TR-TK	Toplam	Açıklama
Eğitim (Train)	30.262	29.671	59.933	Karıştırılmış (seed=42), tek train.jsonl
Doğrulama (Valid)	750	750	1.500	Dengeli, dil bazlı ayrık bölüm
İç Test (Test)	750	750	1.500	Dahili değerlendirme kümesi
FLORES-200 Benchmark	2.009	2.009	4.018	dev(997)+devtest(1012), dış ölçüt
GENEL TOPLAM	33.771	33.180	66.951	—

FLORES-200 verisi için Meta'nın veri setinin doğrulama (dev) ve test (devtest) parçaları birleştirilerek her dil için 2.009 cümlelik bağımsız bir uluslararası ölçüt seti oluşturulmuştur. Bu set eğitim sürecinde hiçbir şekilde kullanılmamıştır.

3.6. Veri Ön İşleme ve Tokenizasyon

Model eğitime alınmadan önce veriler dil çiftine göre ayrıştırılmış ve her grup kendi hedef dil koduyla ayrı ayrı tokenize edilmiştir. Bu yaklaşım, NLLB-200 tokenizer'ının hedef dil etiketini (azj_Latn veya tuk_Latn) labels tensörünün başına doğru biçimde ekleyebilmesi için zorunludur. Aksi hâlde modelin hedef dili yanlış öğrenmesi riski doğmaktadır.

Ön işleme adımları sırayla uygulanmıştır: dil bazlı bölümlendirme, kaynak dil sabitlemesi (tokenizer.src_lang = "tur_Latn"), hedef dil ataması, DataCollatorForSeq2Seq ile dinamik dolgu, ardından iki dil kümesinin birleştirilmesi ve seed=42 ile karıştırılması. Bu süreçte padding=False seçilmiş; dolgu DataCollatorForSeq2Seq tarafından 8'in katı boyutlarda (FP16 optimizasyonu için) dinamik olarak uygulanmıştır.

3.7. Model Yapılandırması ve LoRA Konfigürasyonu

Temel model FP16 formatında GPU'ya yüklenmiş; ardından PEFT kütüphanesiyle LoRA adaptörü eklenmiştir. Temel modelin bellek izi yaklaşık 1,23 GB VRAM iken LoRA adaptörü eklenmesiyle bu değer 1,28 GB'a yükselmiştir.

Çizelge 3.5. Model ve LoRA Konfigürasyonu

Parametre	Değer
Temel Model	facebook/nllb-200-distilled-600M
Toplam Parametre	615.073.792
Eğitilebilir Parametre (LoRA)	8.650.752
Eğitilebilir Oran	%1,39
VRAM — Temel Model	1,23 GB
VRAM — LoRA Sonrası	1,28 GB
Tokenizer Sözcük Dağarcığı	256.204 token
TR-AZ Hedef Dil Tokeni	azj_Latn (ID: 256020)
TR-TK Hedef Dil Tokeni	tuk_Latn (ID: 256182)

3.8. Eğitim Stratejisi ve Hiperparametreler

Model eğitimi, çok dilli değerlendirme desteği sağlayan özel bir CustomTrainer sınıfıyla yürütülmüştür. Doğrulama aşaması TR-AZ ve TR-TK için eş zamanlı gerçekleştirilmiş; en iyi model TR-AZ doğrulama BLEU skoruna göre belirlenmiş ve EarlyStoppingCallback (patience=1) ile korunmuştur.

Çizelge 3.6. Eğitim Hiperparametreleri

Hiperparametre	Değer	Açıklama
Epoch Sayısı	4	Erken durdurma ile korunmuş
Cihaz Başına Batch	16	T4 için optimize edilmiş
Gradyan Birikimi	4 adım	Efektif batch boyutu: 64
Öğrenme Oranı	3×10^{-4}	LoRA için yüksek LR
LR Planlayıcı	Cosine	Düzgün ısınma + azalma
Isınma Adımı	187	Toplam adımların %5'i
Hassasiyet	FP16	Bellek ve hız optimizasyonu
Gradient Checkpointing	Açık	OOM önlemi
Değerlendirme Stratejisi	Epoch başına	Her epoch sonunda

Hiperparametre	Değer	Açıklama
En İyi Model Metriği	eval_tr-az_bleu	TR-AZ BLEU maksimizasyonu
Toplam Eğitim Süresi	7.593 saniye	≈2 saat 6 dakika

Eğitim tamamlandıktan sonra LoRA adaptör ağırlıkları `merge_and_unload()` ile temel modele birleştirilerek PEFT bağımlılığı kaldırılmış ve model bağımsız kullanıma hazır hâle getirilmiştir. Nihai model ağırlıkları, açık kaynaklı kullanım için Hugging Face Hub platformuna (Zuhtu-Hilmi/TurkDilleriNMT) yüklenmiştir.

4. BULGULAR VE TARTIŞMA

4.1. Taban Model (Saf Model) Başarımı

İnce-ayar yapılmadan önce NLLB-200-distilled-600M modelinin saf başarımı ölçülmüş ve referans değerleri belirlenmiştir. Bu ölçüm hem sonraki iyileştirmeyi nicel olarak ortaya koymak hem de önceki dönem (MarianMT, BLEU $\approx$ 1,00) ile büyük resmi kıyaslamak amacıyla kritik önem taşımaktadır.

Çizelge 4.1. Taban (Saf) Model Başarımı

Dil Çifti	Veri Seti	BLEU	chrF	METEOR
TR-AZ	Dahili Test	14,40	44,74	0,4206
TR-AZ	FLORES-200	9,96	41,39	0,3059
TR-TK	Dahili Test	12,56	39,57	0,3519
TR-TK	FLORES-200	7,18	35,57	0,2447

Taban model değerlendirmesi, NLLB-200'ün ön-eğitim sırasında bu dil çiftlerine kısmi düzeyde maruz kaldığını ve sıfır-atış (zero-shot) çeviride belli bir başarımla sergilediğini göstermektedir. FLORES-200 skorlarının dahili test skorlarına göre belirgin biçimde düşük kalması ise modelin genel amaçlı metinlerde zayıf kaldığına ve bu dil çiftleri için ön-eğitim verisinin kısıtlı olduğuna işaret etmektedir.


4.2. Eğitim Süreci Bulguları

Model 4 epoch boyunca eğitilmiş; her epoch sonunda TR-AZ ve TR-TK için bağımsız değerlendirme metrikleri hesaplanmıştır. Aşağıdaki çizelgede eğitim ve doğrulama kayıplarının (loss) yanı sıra başarımların epoch bazlı gelişimi sunulmaktadır.

Çizelge 4.2. Epoch Bazlı Eğitim ve Doğrulama Metrikleri

Epoch	Eğitim Kaybı	AZ Kaybı	AZ BLEU	AZ chrF	TK Kaybı	TK BLEU	TK chrF
1	5,8850	1,4855	24,71	53,77	1,1644	33,52	61,97
2	5,3519	1,4400	25,20	54,07	1,0320	37,69	65,77
3	4,9562	1,4259	25,67	54,34	0,9833	39,18	66,78
4	4,9105	1,4259	25,86	54,50	0,9766	39,78	67,00

Şekil 4.1. Epoch Bazlı Global Eğitim ve Dil Bazlı Doğrulama Kaybı (Loss) Grafikleri



Şekil 4.1'de görselleştirilen kayıp eğrileri, eğitim sürecinin dinamiğini net biçimde ortaya koymaktadır. Sol panelde (A) global eğitim kaybının istikrarlı bir şekilde 5,88'den 4,91'e düştüğü görülmektedir. Sağ panelde (B) ise diller arası öğrenme farkı belirgindir: TR-AZ doğrulama kaybı 3. epoch civarında yatay bir seyre geçerek (1,4259) erken yakınsama (convergence) sinyali verirken, TR-TK doğrulama kaybı 4. epoch'a kadar (0,9766) iyileşmeye devam etmiştir. Bu grafiksel kanıt, Alpaca tabanlı sentetik verinin TR-TK yönünde modelin öğrenme kapasitesini uzun süre desteklediği tezini doğrulamaktadır.

TR-TK'nın TR-AZ'ye kıyasla tutarlı biçimde yüksek BLEU değerleri sergilemesi dikkat çekmektedir. Bu durumun başlıca açıklaması, Türkmencenin Türkçeye olan köken yakınlığının ve Alpaca sentetik verisinin içerdiği geniş tematik çeşitliliğin modeli daha zengin bir bağlamsal temsil öğrenmeye yönlendirmesidir.

4.3. İnce-Ayarlı Model Başarımı

İnce-ayar tamamlandıktan sonra model hem dahili test kümesinde hem de FLORES-200 uluslararası karşılaştırma ölçütünde bağımsız olarak değerlendirilmiştir.

Çizelge 4.3. Taban ve İnce-Ayarlı Model Karşılaştırmalı Başarımı

Dil Çifti	Model	Veri Seti	BLEU	chrF	METEOR
TR-AZ	Taban (Saf)	Dahili Test	14,40	44,74	0,4206
TR-AZ	İnce-Ayarlı	Dahili Test	25,19 (+10,79)	54,04	0,5354
TR-AZ	Taban (Saf)	FLORES-200	9,96	41,39	0,3059

Dil Çifti	Model	Veri Seti	BLEU	chrF	METEOR
TR-AZ	İnce-Ayarlı	FLORES-200	10,80 (+0,84)	43,54	0,3224
TR-TK	Taban (Saf)	Dahili Test	12,56	39,57	0,3519
TR-TK	İnce-Ayarlı	Dahili Test	39,56 (+27,00)	65,79	0,6248
TR-TK	Taban (Saf)	FLORES-200	7,18	35,57	0,2447
TR-TK	İnce-Ayarlı	FLORES-200	11,34 (+4,16)	44,79	0,3313

Dahili test kümesinde TR-TK için elde edilen +27,00 birimlik BLEU artışı özellikle dikkat çekicidir. Bu olağanüstü iyileşme, üç faktörün bir araya gelmesinin sonucudur: (1) NLLB-200'ün bu dil çiftine yönelik sıfır-atış başarımının oldukça düşük başlamış olması; (2) Alpaca sentetik verisinin tematik zenginliğinin güçlü bir ince-ayar sinyali oluşturması; (3) Türkmencenin Türkçeye olan yapısal benzerliğinin LoRA adaptasyonunu kolaylaştırması.

4.4. Performans Değerlendirmesi

Sistem kaynak kullanımı açısından incelendiğinde son derece verimli bir profil gözlemlenmiştir:

Çizelge 4.4. Sistem Kaynak Kullanımı

Metrik	Değer
GPU	Tesla T4 (15,6 GB VRAM)
Toplam Eğitim Süresi	7.593 saniye (≈2 sa 6 dk)
Toplam Eğitim Adımı	3.748
Eğitilebilir Parametre Oranı	%1,39 (LoRA)
Model Dosya Boyutu (safetensors)	1.230,2 MB
Ortalama Eğitim Kaybı	5,4337

Gradient checkpointing ve FP16 hassasiyet bileşimi, 15,6 GB VRAM kapasiteli T4 GPU üzerinde herhangi bir bellek taşması (OOM) yaşanmadan eğitimin tamamlanmasını sağlamıştır. LoRA'nın yalnızca 8,65M parametre güncellemesiyle bu düzeyde başarımların artışı sağlanması, yöntemin parametre verimliliğini açıkça doğrulamaktadır.

4.5. Nitel Analiz: Örnek Çeviri Karşılaştırmaları

Sayısal metriklerin yanı sıra, ince-ayarın çeviri kalitesine olan nitel katkısını görselleştirmek amacıyla test kümesinden seçilen örnek cümleler üzerinde taban model ile ince-ayarlı modelin çıktıları karşılaştırmalı olarak incelenmiştir. Bu karşılaştırma, modelin gerçekte hangi dil sorunlarını çözüp hangilerinde yetersiz kaldığını kelime düzeyinde ortaya koymaktadır.

Çizelge 4.5. TR-AZ Örnek Çeviri Karşılaştırmaları

Rol	Cümle 1 (Günlük Dil)	Cümle 2 (Haber/Akademik)	Cümle 3 (Teknik)
Kaynak (TR)	Teşekkür ederim, görüşürüz.	Hükümet, ekonomik kalkınma için yeni politikalar açıkladı.	Bu projenin temel amacı doğrudan çeviri altyapısı kurmaktır.
Taban NLLB	Təşəkkürlər, görüşəcəyik.	Hökumət iqtisadi inkişaf üçün yeni siyasətlər açıqlayıb.	Bu layihənin əsas məqsədi birbaşa tərcümə infrastrukturunu qurmaqdır.
İnce-Ayarlı	Təşəkkür edirəm, görüşəcəyik.	Hökumət iqtisadi inkişaf üçün yeni siyasətlər açıqladı.	Bu layihənin əsas məqsədi birbaşa tərcümə infrastrukturunu qurmaqdır.

TR-AZ karşılaştırmaları incelendiğinde, ince-ayarlı modelin özellikle morfolojik zaman kiplerinde mükemmel bir hassasiyet kazandığı görülmektedir. Cümle 2'de taban model, Türkçe "-DI" geçmiş zaman ekini "açıqlayıb" şeklinde belirsiz geçmiş zamana çevirirken; ince-ayarlı model kaynak cümleye tam sadık kalarak "açıqladı" şeklinde kesin geçmiş zaman üretmiştir. Cümle 3'te ise her iki modelin de birebir aynı ve kusursuz teknik çeviriyi yaptığı görülmüştür. Bu durum, LoRA ince-ayarının temel modelin ön-eğitimden getirdiği doğru bilgileri bozmadan koruduğunu (felaketsel unutmamanın engellendiğini) kanıtlamaktadır.

Çizelge 4.6. TR-TK Örnek Çeviri Karşılaştırmaları

Rol	Cümle 1 (Günlük Dil)	Cümle 2 (Talimat Tabanlı)	Cümle 3 (Plan/Gelecek)
Kaynak (TR)	Çocuklar bahçede oyun oynuyor.	Lütfen bu soruyu açık bir şekilde yanıtlayın.	Gelecek yıl yeni bir bilgisayar almayı planlıyorum.
Taban NLLB	Çağalar bağda oynayırlar.	Bu soraga aýdyň jogap beriň.	Men geljek ýyl täze kompýuteri aljak bolýaryn.

Rol	Cümle 1 (Günlük Dil)	Cümle 2 (Taliat Tabanlı)	Cümle 3 (Plan/Gelecek)
İnce-Ayarlı	Çagalar bagda oýun oýnaýarlar.	Haýyş bu soraga açyk jogap beriň.	Geljek ýylda täze kompýuter satyn almagy maksat edinýäriň.

TR-TK yönündeki sonuçlar, ince-ayarın modele kattığı devasa kelime dağarcığı sıçramasını gözler önüne sermektedir. Cümle 1'de taban model kaynak metindeki "oyun" kelimesini yutarken (omission), ince-ayarlı model "oýun oýnaýarlar" ifadesini eksiksiz üretmiştir. Cümle 2'de taban model "Lütfe" ifadesini tamamen atlamışken, ince-ayarlı model "Haýyş" kelimesiyle komutu başarılı biçimde başlatmıştır. En dikkat çekici gelişim ise Cümle 3'tedir: Taban model "planlıyorum" ifadesini "aljak bolýaryň" (alacak oluyorum) gibi zayıf bir yapıyla kurmaya çalışırken, ince-ayarlı model "satyn almagy maksat edinýäriň" (satın almayı maksat ediniyorum/planlıyorum) şeklinde üst düzey ve akademik bir Türkmençe üretmiştir. Bu durum, modele entegre edilen Alpaca verilerinin sözdizimsel katkısını net biçimde kanıtlamaktadır.

4.6. FLORES-200 Karşılaştırma Analizi ve Aşırı Uyum

FLORES-200 sonuçları, dahili test kümesiyle kıyaslandığında kayda değer bir başarımlı düşüşü göstermektedir: TR-AZ için 25,19'dan 10,80'e, TR-TK için ise 39,56'dan 11,34'e gerileme gözlemlenmiştir. Bu bulgular, SDD NFR-01 başarımlı hedeflerini (TR-AZ FLORES BLEU ≥ 25 , TR-TK FLORES BLEU ≥ 18) karşılayamamış; ancak taban model değerleriyle kıyaslandığında TR-AZ'de +0,84, TR-TK'da ise +4,16 birimlik FLORES iyileşmesi kayıt altına alınmıştır.

Bu çarpıcı farkı açıklamaya yönelik birden fazla etken saptanmıştır:

- **Alan Kayması (Domain Shift):** Dahili eğitim verisi belirli kaynak ve alan kombinasyonlarını yansıtırken FLORES-200, bilim, toplum, kültür, spor ve güncel olayları kapsayan geniş bir tematik yelpazeden oluşmaktadır. Bu dağılım farkı, modelin alan dışı (out-of-domain) veride zayıflamasına yol açmaktadır.
- **Sentetik Veri Kaynaklı Dağılım Sapması:** TR-TK çiftinde eğitim verisinin yaklaşık %60'ını oluşturan LLM tarafından üretilmiş Alpaca komut-cevap formatındaki sentetik veriler, modelin dahili test setinde yüksek başarımlı göstermesini sağlamıştır. Ancak bu veri, yapı ve ton açısından FLORES-200'deki doğal, akademik ve gazetecilik kökenli metinlerden belirgin biçimde

farklılaşmaktadır. Bu dağılım sapması (distributional shift), modelin FLORES karşısında zorlanmasının temel açıklamasını sunmaktadır.

- **Eğitim Kümesine Aşırı Uyum:** Taban ve ince-ayarlı model FLORES skorları arasındaki sınırlı fark, modelin eğitim verisinin dil kalıplarını ezberleyip genel dil yapılarına tam olarak genelleyemediğine işaret etmektedir. Daha fazla alan çeşitliliği içeren ve organik insan çevirilerinden oluşan veri bu durumu iyileştirebilir.
- **Maksimum Token Kısıtı:** Eğitim sırasında uygulanan 128 token sınırı, FLORES-200'deki uzun ve karmaşık akademik cümlelerin işlenmesini kısıtlamıştır. Değerlendirme aşamasında sınır 256 tokena çıkarılmış olsa da bu değişiklik mevcut model ağırlıklarını etkilememiştir.

Bu bulgular bir başarısızlık olarak değil, veri mühendisliği ve genelleme kapasitesi arasındaki dengeye ilişkin önemli bir akademik ders olarak değerlendirilmelidir. Sentetik veri kullanımının dahili başarıyı olağanüstü yükselttiği, ancak alan çeşitliliğini kısıtladığı bu proje, düşük kaynaklı NMT alanında hibrit veri stratejilerinin potansiyel ve sınırlılıklarını somut biçimde ortaya koymaktadır.

5. SONUÇ VE ÖNERİLER

Bu çalışmada, Türkçe-Azerbaycanca ve Türkçe-Türkmence dil çiftleri için İngilizce aracı dil kullanmadan doğrudan çeviri yapabilen çok dilli bir NMT sistemi başarıyla geliştirilmiştir. Proje iki açıdan önceki dönemden köklü biçimde ayrılmaktadır: (1) Mimari: MarianMT'den NLLB-200 + LoRA'ya geçiş; (2) Veri: Basit corpus toplama yerine üç katmanlı hibrit veri mühendisliği stratejisi.

Projenin temel bulguları şu şekilde özetlenebilir:

8. Önceki Dönemle Kıyaslama: Geçen dönem MarianMT ile 1,00 BLEU seviyesinde kalan problem, bu dönem NLLB-200 + LoRA mimarisine geçilerek dahili test kümesinde TR-TK için 39,56 BLEU seviyesine taşınmış; yaklaşık 40 birimlik devasa bir başarımlı sıçraması gerçekleştirilmiştir.
9. Veri Mühendisliği Başarısı: Doğrudan paralel derlem, pivot madenciliği ve LLM destekli sentetik üretim bileşenlerini harmanlayan hibrit stratejiyle 66.951 satırlık yüksek kaliteli paralel veri havuzu oluşturulmuştur.
10. LoRA Verimliliği: Toplam parametrelerin yalnızca %1,39'unu güncelleyen LoRA adaptörü, yaklaşık 2 saatlik eğitimle anlamlı başarımlı artışları sağlamıştır. Bu bulgu, LoRA'nın düşük kaynaklı NMT ince-ayarı için uygun maliyetli ve verimli bir yöntem olduğunu doğrulamaktadır.
11. Sentetik Verinin Çift Etkisi: Alpaca ve OpenSubtitles bazlı sentetik veriler dahili başarımlı güçlendirmiş; ancak bu verilerin dağılımsal homojenliği FLORES-200 genelleme kapasitesini kısıtlamıştır. Bu ikilemin farkında olmak, gelecek veri mühendisliği kararlarını yönlendirecektir.
12. FLORES Hedefleri: SDD NFR-01 başarımlı hedefleri (TR-AZ BLEU ≥ 25 , TR-TK BLEU ≥ 18) FLORES-200 ölçütünde karşılanamamıştır. Bu durum, gelecek çalışmalar için açık ve somut bir geliştirme gündemi sunmaktadır.

Gelecekteki çalışmalar için aşağıdaki öneriler sunulmaktadır:

- Alan Çeşitliliğinin Artırılması: Haber makaleleri, akademik metinler ve sosyal medya içerikleri gibi farklı alanlardan derlenen verilerle modelin FLORES genellemesi güçlendirilebilir.

- Sentetik Kalite Denetiminin Güçlendirilmesi: DD belgesinde tasarlanan Gemini Pro tabanlı LLM-as-a-Judge yöntemi hayata geçirilerek yalnızca $\geq 8,0$ kalite puanı alan sentetik çiftlerin eğitime alınması aşırı uyumu azaltabilir.
- Kapsamın Özbekçe ve Kazakçaya Genişletilmesi: DD belgesinde tanımlanan <2xx> dil etiketi mimarisi sayesinde yeni Türk dilleri mevcut sisteme kolayca entegre edilebilir.
- NLLB-200-1.3B Varyantına Geçiş: Daha güçlü donanım altyapısı sağlandığında büyük modelin LoRA ile ince-ayarı denenerek başarımları kazanımları karşılaştırmalı olarak incelenebilir.
- İnsan Değerlendirmesi: Otomatik metriklere ek olarak insan değerlendiricilerle niteliksel bir kullanıcı çalışması yapılarak modelin gerçek senaryolardaki akıcılığı ve anlam doğruluğu ölçülebilir.

Bu proje, Türkçe-Azerbaycanca ve Türkçe-Türkmence dil çiftleri için düşük kaynaklı, doğrudan ve açık kaynak kodlu bir çeviri tabanı oluşturmaktadır. Geliştirilen hibrit veri mühendisliği metodolojisi ve LoRA ince-ayar yaklaşımı, bu alandaki gelecek akademik ve endüstriyel çalışmalar için somut ve tekrarlanabilir bir çerçeve sunmaktadır.

KAYNAKLAR

- Banerjee, S. ve Lavie, A. (2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation*, 65-72.
- Gemini Team, Google. (2023). Gemini: A family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S. ve Chen, W. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations (ICLR)*.
- Koehn, P. (2010). *Statistical Machine Translation*. Cambridge University Press.
- Mangrulkar, S., Gugger, S., Debut, S., Belkada, S. ve Paul, S. (2022). *PEFT: State-of-the-art Parameter-Efficient Fine-Tuning methods*. <https://github.com/huggingface/peft>.
- NLLB Team. (2022). No Language Left Behind: Scaling Human-Centered Machine Translation. *arXiv preprint arXiv:2207.04672*.
- Papineni, K., Roukos, S., Ward, T. ve Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, 311-318.
- Popovic, M. (2015). chrF: character n-gram F-score for automatic MT evaluation. *Proceedings of the Tenth Workshop on Statistical Machine Translation*, 392-395.
- Post, M. (2018). A call for clarity in reporting BLEU scores. *Proceedings of the Third Conference on Machine Translation: Research Papers*, 186-191.
- Salimov, F., Yusufli, T. ve Aliyev, V. (2023). Turkish-Azerbaijani neural machine translation without English as pivot language. *Proceedings of the International Conference on Computational Linguistics*.
- Taori, R., Gulrajani, I., Zhang, T., Dubois, Y., Li, X., Guestrin, C., Liang, P. ve Hashimoto, T. B. (2023). *Stanford Alpaca: An Instruction-following LLaMA model*. https://github.com/tatsu-lab/stanford_alpaca.
- Tatoeba Project. (2024). *Tatoeba: Collection of sentences and their translations*. <https://tatoeba.org> (Erişim tarihi: Mart 2026).
- Tiedemann, J. (2012). Parallel Data, Tools and Interfaces in OPUS. *Proceedings of the Eighth International Conference on Language Resources and Evaluation (LREC)*.
- TurkicNLP. (2024). *Universal Dependencies Treebanks for Turkic Languages*. <https://github.com/turkicnlp> (Erişim tarihi: Şubat 2026).
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. ve Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Wolf, T. vd. (2020). Transformers: State-of-the-Art Natural Language Processing. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 38-45.
- Xu, L., Huang, K., Song, S. ve Dong, L. (2023). Parameter-efficient fine-tuning of large language models for multilingual machine translation. *arXiv preprint arXiv:2312.01303*.

EKLER

Ek 1 – Eğitim Kodu (TurkDilleriNMT_Colab_yeni_kod.py)

Ek 2 – Veri Seti Kaynak Dağılımı Detayları

Ek 1 – Eğitim Kodu

Projenin tüm eğitim ve değerlendirme kodu Google Colab ortamında TurkDilleriNMT_Colab_yeni_kod.py dosyası olarak hazırlanmıştır. Kodun ana hücreleri ve işlevleri aşağıda özetlenmiştir:

Hücre	Amaç
Hücre 1	Google Drive bağlantısı, kütüphane kurulumu, sabit yol değişkenleri
Hücre 2	NLLB-200 tokenizer yükleme, dil kodu haritası oluşturma
Hücre 3	preprocess_function ve DataCollatorForSeq2Seq tanımlama
Hücre 4	JSONL yükleme, dil bazlı bölümlleme ve tokenizasyon
Hücre 5	Temel model yükleme (FP16, GPU otomatik eşleme)
Hücre 5.1	compute_metrics fonksiyonu (BLEU + chrF + METEOR)
Hücre 5.5	Taban model başarıml ölçümü (dahili test + FLORES-200)
Hücre 6	LoRA konfigürasyonu ve PEFT adaptörü
Hücre 8	CustomTrainer sınıfı (çok dilli değerlendirme desteği)
Hücre 9	Seq2SeqTrainingArguments tanımlama
Hücre 10	Trainer başlatma ve eğitim
Hücre 11	Test seti + FLORES-200 final değerlendirmesi
Hücre 12	LoRA merge ve model kaydetme

Ek 2 – Veri Seti Kaynak Dağılımı Detayları

Aşağıdaki çizelge, her veri kaynağının dile özgü katkı miktarını, türünü ve veri havuzuna entegrasyon yöntemini özetlemektedir.

Kaynak	Tür	TR-AZ Satır	TR-TK Satır	Entegrasyon Yöntemi
TurkicNLP	Doğrudan Paralel	7.203	7.135	Ham indirme + UTF-8 doğrulama
TED2020	Doğrudan Paralel	11.123	209	OPUS API + temizleme boru hattı
Tatoeba	Doğrudan/Pivot	1.123	50	Doğrudan eşleşme + EN köprüsü
Wikimedia	Doğrudan Paralel	—	667	Wikimedia dumps
Pivot (EN)	Köprü Madenciliği	3.296	3.096	Algoritmik çift eşleştirme
OpenSubtitles + Gemini	LLM Sentetik	9.017	—	Gemini API (AZ→TR çeviri)
Alpaca + Gemini	LLM Sentetik	—	20.014	Gemini API (TK→TR çeviri)
TOPLAM (Havuz)	—	31.762	31.171	—

Tüm sentetik veriler üretim sonrasında uzunluk filtresi ve dil doğrulama adımlarından geçirilmiştir. Organik kaynaklardan gelen veriler ise Bölüm 3.3'te ayrıntılandırılan çok adımlı temizleme boru hattına tabi tutulmuştur.